

Eğitsel-KBRAG: Öğrenci Etkileşimi Odaklı Konuşma Belleği Tabanlı Geri Kazanım Destekli Üretim Sistemi

Adaptif Eğitim Platformları İçin Aktif Öğrenme ve Sürekli Geri Bildirim Döngüsü ile Adaptif Eğitim Platformu

Hazırlayan Engin Dalga

Tarih Ekim 2025

Özet (Abstract)

Yapay zeka (YZ) destekli eğitim sistemleri, öğrencilerin bireysel ihtiyaçlarına uyum sağlama konusunda önemli potansiyele sahiptir. Bu çalışma, **Erişim Artırılmış Üretim (Retrieval-Augmented Generation - RAG)** teknolojisini eğitim alanının özgün gereksinimlerine göre şekillendiren **Eğitsel-KBRAG** sistemini sunmaktadır. Mevcut RAG sistemleri, genellikle statik erişim stratejileri benimsemekte ve kullanıcı geri bildirimlerini yetersiz kullanmaktadır.

Önerilen sistem, **üç temel yenilik** üzerine kurulmuştur: her öğrenci etkileşiminin kaydeden konuşma belleği mimarisi, emoji tabanlı mikro-geri bildirim mekanizması ve Conversation-Aware Content Scoring (CACS) algoritması. Eğitsel-KBRAG, AL4RAG'ın (Geng et al., 2025) diyalog kayıtları yaklaşımını öğrenci profileme amacıyla genişletmektedir, SELF-RAG'ın (Asai et al., 2024) yansıtma (reflection) mekanizmasını öğrenci geri bildirimleriyle besleyerek gerçek zamanlı adaptasyon sağlamaktadır, ve **pedagojik teorileri** (Yakınsal Gelişim Alanı - ZPD, Bloom Taksonomisi ve Bilişsel Yük Teorisi) sistem mimarisine entegre etmektedir. Bu bütüncül yaklaşım, teknik doğruluğu **Uzman Döngüsü** ile ve pedagojik faydayı **Öğrenci Döngüsü** ile optimize eden Evrimsel RAG mimarileri (AURA/CoTAL) ile uyumludur.

Anahtar Kelimeler: RAG, Konuşma Belleği, Aktif Öğrenme, Adaptif Eğitim, Kişiselleştirme, Pedagojik Teori.

1. Giriş

1.1. Motivasyon ve Araştırma Bağlamı

Büyük Dil Modelleri (LLM) ile eğitim teknolojilerinin gelişimi hız kazanmış, kişiselleştirilmiş destek sağlayan sistemler geliştirmek pratik bir hedef haline gelmiştir. Ancak bu sistemlerin entegrasyonu, teknik başarının ötesinde **pedagojik derinlik** gerektirmektedir. Eğitim bağlamında, bir öğrencinin sorusuna verilen cevabın kalitesi, sadece ilgili dokümanların bulunmasıyla değil, aynı zamanda o öğrencinin mevcut bilgi seviyesi, öğrenme tercihleri ve geçmişteki etkileşimleriyle de şekillenmelidir.

1.2. Literatürden Bulgular ve Mevcut Sınırlılıklar

Mevcut LLM tabanlı eğitim sistemlerinde önemli ilerlemeler kaydedilmiştir, ancak Eğitsel-KBRAG'ın hedeflediği alanlarda temel eksiklikler sürmektedir:

- **Kişiselleştirme ve Bağlamsal Süreklik Eksikliği:** LPiTutor sistemi (Liu et al., 2025), RAG ve istem mühendisliğini birleştirerek etkinliği artırmıştır, ancak öğrenci etkileşim geçmişini **uzun vadeli profillere dönüştürme konusunda sınırlı kalmıştır**. Benzer şekilde, alan özgü chatbot vaka çalışmaları, etkileşim geçmişini oturum bazlı (session-based) kullanmaktadır.

- **Geri Bildirim Döngüsünün Zayıflığı:** NotebookLM (Tufino, 2025) gibi platformlar, RAG ile izlenebilir yanıtlar sunsa da, **öğrenci geri bildirimini sistematik olarak toplayıp optimizasyon için kullanmakta yetersizdir**.

Halihazırda kullanılan sistemlerde gözlemlenen temel eksiklikler şunlardır: (1) Bireyselleşme eksikliği, (2) Geri bildirim döngüsünün zayıflığı ve (3) Öğrenme yolculuğunun izlenememesi nedeniyle **bağlamsal süreklilik eksikliği**.

1.3. Araştırma Soruları

Bu çalışma, yukarıda belirtilen boşlukları ele alarak şu temel soruları yanıtlamayı hedeflemektedir:

1. Konuşma geçmişi sistematik olarak kaydedilip analiz edildiğinde, RAG sistemleri öğrencilere daha iyi yanıtlar sunabilir mi?
 2. Öğrencilerden toplanan mikro-geri bildirimler, sistem performansını gerçek zamanlı olarak iyileştirebilir mi?
 3. Eğitim bilimlerinin temel teorileri RAG sistemlerinin mimarisine nasıl entegre edilebilir?
-

2. İlgili Çalışmalar ve Literatür Değerlendirmesi

Eğitsel-KBRAG, LLM destekli eğitim için pedagojik derinliği, adaptif hafıza yönetimini ve güvenilirliği sağlamak amacıyla ileri RAG çerçevelerinin (SELF-RAG, AL4RAG, Amber, CDF-RAG, CoTAL, Persona-RAG, Pistis-RAG) en kritik mekanizmalarını sentezleyen hibrit bir yaklaşımdır.

2.1. Güvenilirlik ve Adaptasyon Odaklı RAG Çerçeve

2.1.1. Öz-Yansıtmalı Erişim (SELF-RAG)

SELF-RAG (Asai et al., 2024), modelin kendi üretim sürecini değerlendirmesini sağlayan yansıtma belirteçleri (reflection tokens) kullanarak özerk bir eleştiri yaklaşımı sunmuştur. Bu belirteçler (Retrieve, ISREL, ISSUP, ISUSE) sayesinde model, **harici bilgiye ne zaman ihtiyaç duyduğuna özerk karar verebilir**. Eğitsel-KBRAG, SELF-RAG'ın yansıtma mekanizmasını, öğrenci geri bildirimleriyle beslenen bir sisteme dönüştürmeyi amaçlar.

2.1.2. Aktif Öğrenme ve Reddetme Yeteneği (AL4RAG)

AL4RAG (Geng et al., 2025), LLM'lerin temel sorunu olan **halüsinosyon riskini azaltmak** için Aktif Öğrenme (AL) kullanır ve modeli "**Yeteneklileri Cevapla, Yeteneksizleri Reddet**" stratejisi doğrultusunda eğitir. AL4RAG'ın ana yeniliği, RAG verilerinin üç öznitelikli yapısına (sorgu q , referans r , yanıt a) özel olarak tasarlanmış **Retrieval-Augmented Similarity (ras)** metriğidir. Bu metrik, geleneksel benzerlik ölçümlerinin aksine, uzun referans belgelerinin kısa sorgunun kritik etkisini baskılamasını engeller.

2.2. Adaptif Akıl Yürütmeye ve Hafıza Yönetimi

2.2.1. Ajan Tabanlı Hafıza Optimizasyonu (Amber)

Amber (Qin et al., 2025), özellikle **çok aşamalı (multi-hop) QA** görevlerinde RAG'ın **hafıza eksikliğini ve gürültü sorununu** çözmeyi amaçlar. Amber, yinelemeli bir hafıza güncelleme paradigması kullanır ve üç ana bileşenden oluşur: **Ajan Tabanlı Hafıza Güncelleyici (AMU)**, **Adaptif Bilgi Toplayıcı (AIC)** ve **Çok Taneli İçerik Filtresi (MCF)**. Bu ajan işbirliği, önceki erişim adımlarından gelen bilgileri optimize edilmiş bir **kümülatif hafızaya** entegre eder.

2.2.2. Nedensel Dinamik Akıl Yürütmeye (CDF-RAG)

CDF-RAG (CDF-RAG authors, 2025), geleneksel RAG'ın salt anlamsal benzerliğe dayanarak **neden-sonuç ilişkilerini** kuramaması sorununu ele alır. Sistem, Takviyeli Öğrenme (RL) ile eğitilmiş bir Sorgu İyileştirme ajanı kullanarak kullanıcının sorgusunu, nedensel erişim için optimize edilmiş bir sorguya dönüştürür. CDF-RAG, çift yolu erişim (semantik vektör erişimi) ve **nedensel bilgi çizgesi** geçişini uygulayarak, üretilen yanittaki nedensel iddiaların desteklenip desteklenmediğini bir **Nedensel Çizge Kontrolü** ile doğrular.

2.3. Pedagojik Hızalama ve İnsan Döngüsü

2.3.1. İnsan Döngüsü Destekli İstem Mühendisliği (CoTAL)

CoTAL (Cohn et al., 2025), LLM'leri öğretmen beklentileriyle hizalamak ve açık uçlu biçimlendirici değerlendirme puanlaması için tasarlanmıştır. CoTAL'in temel gücü, **Aktif Öğrenme** kullanarak LLM'nin en çok hata yaptığı "**yapışma noktası**" örneklerini hedefli bir şekilde seçmesi ve **Zincirleme Düşünce (CoT)** istemi ile puanlama kararlarını rubrik ve öğrenci kanıtlarıyla ilişkilendirmesini zorunlu kılmıştır.

2.3.2. Öğrenci Tercihleriyle Sıralama ve Bilişsel Adaptasyon

• **Pistis-RAG** (Bai et al., 2024), LLM çıktılarını **insan tercihleriyle hizalamak** için tasarlanmıştır. Sistem, kullanıcının eylemlerini (Copy, Regenerate, Dislike) gösteren **Liste**

Çapında Etiketler (List-wide Labels) kullanarak sıralayıcıyı çevrimiçi öğrenmeyle eğitir. Eğitsel-KBRAG'ın mikro-geri bildirimini bu hizalama sürecini başlatır.

- **Persona-RAG** (Persona-RAG authors, 2025), öğrenci ajanlarının **bilişsel stillerine** (VAK, Kolb) uyum sağlamak için tasarlanmıştır. Sorguyu doğrudan soruya göre değil, öğrencinin bilişsel özelliklerine göre oluşturulan **kişiselleştirilmiş bir akıl yürütme planına** göre ayırtırır.
 - **SDLChat** (Liu et al., 2025), RAG'ı Öğrenme Analitiği Gösterge Tablosu (LAD) verileriyle birleştirerek, öğrencinin davranışsal verilerine dayalı kişiselleştirilmiş teşhis raporları üretir ve **Öz Yonelimi Öğrenmeyi (SDL)** destekler.
-

3. Sistem Mimarisi ve Tasarım

Eğitsel-KBRAG, AURA mimarisinden esinlenilmiş, hibrit ve modüler bir yapıyı benimser.

3.1. Genel Mimari

Sistem beş ana katmandan oluşmaktadır:

1. **RAG Layer:** Mevcut belge erişimi ve LLM entegrasyonu.
2. **Conversation Memory Layer:** Yapılandırılmış depolama (SQLite) ile **uzun vadeli profil verilerini** tutar. Bu katman, Amber'in Ajan Tabanlı Hafiza Güncelleyici (AMU) konseptini taklit eder.
3. **Business Logic Layer:** CACS algoritması ve Pedagojik Monitörler (ZPD, Bloom, Bilişsel Yük) burada bulunur.
4. **API Layer:** RESTful uç noktalarını içerir.
5. **Frontend Layer:** Kullanıcı arayüzü ve emoji tabanlı geri bildirim mekanizması.

3.2. Konuşma Belleği ve Profilleme

Konuşma belleği sistemi, uzun vadeli profilleme ve adaptasyon için üç ana tablo üzerine inşa edilmiştir:

- **conversation_history:** Öğrencinin soru, yanıt, zaman damgaları, zorluk seviyesi ve **mikro-geri bildirim skoru** gibi etkileşim ve meta verileri kaydeder.
- **student_profiles:** Öğrencinin güçlü/zayıf konuları, öğrenme stili ve mevcut **ZPD seviyesi** gibi pedagojik verileri tutar. Bu profil, Persona-RAG'ın bilişsel özelliklere göre erişimi kişiselleştirme ilkesini destekler.

3.3. Sistem Akışı

Bir öğrenci sorgusu geldiğinde, Eğitsel-KBRAG 14 adımlı bir süreç işletir:

1. Öğrenci sorgusu alınır.
 2. Öğrenci profili ve geçmiş sorguları çekilir.
 3. **CACS** ile doküman skorlaması yapılır.
 4. En yüksek skorlu dokümanlar seçilir.
 5. Cevap, **ZPD** ve **Bloom** seviyelerine göre ayarlanır.
 6. **Bilişsel Yük** kontrolü yapılır.
 7. Yanıt, CoTAL'ın zorunlu kıldığı gibi, geri getirilen kaynaklara **açıkça atıfta bulunarak** ve gerekçelendirerek (CoT) üretilir.
 8. Yanıt, geçmiş kaydına ve profile işlenir.
 9. Öğrenciye **geri bildirim butonları** eklenir.
 10. Öğrenci geri bildirim verir (emoji tabanlı).
 11. İçerik skorları ve profiller güncellenir.
-

4. CACS Algoritması ve Pedagojik Adaptasyon Mekanizmaları

4.1. CACS Algoritması (Conversation-Aware Content Scoring)

CACS, her doküman için öğrenciye özel adaptif skor hesaplar. Bu, dört farklı skorun ağırlıklı kombinasyonu ile gerçekleştirilir.

Formül: $\text{final_score} = w_1 \cdot \text{base_score} + w_2 \cdot \text{personal_score} + w_3 \cdot \text{global_score} + w_4 \cdot \text{context_score}$.

- **personal_score (25%)**: Öğrencinin geçmişteki etkileşimleri ve profili ile dokümanın alaka düzeyini hesaplar. Bu skorlama, LPiTutor'ın dinamik istem enjeksiyonu prensibini takip ederek **kİŞİSELLEŞTİRMEYİ** sağlar.
- **global_score (25%)**: Tüm öğrencilerden toplanan mikro-geri bildirimlere dayalı olarak dokümanın genel faydasını gösterir. Bu skor, Pistis-RAG'in **Liste Çapında Etiketler** ile sıralayıcıyı eğitme stratejisiyle hizalanır.

4.2. Mikro-Geri Bildirim Mekanızması

Sistem, öğrencilerden geri bildirim almayı basit ve hızlı hale getirmek için **emoji tabanlı bir sistem** kullanır. Bu tek tıklamayla geri bildirim, CoTAL'ın Faz III'teki nitel geri bildirim toplama sürecini taklit eder.

Emoji Skorlaması:

- Anladım (0.7): Cevabın anlaşılır olduğunu gösterir.
- Mükemmel (1.0): Cevabın çok açıklayıcı olduğunu belirtir.
- Karışık (0.2): Ek açıklama gerektiğini belirtir.
- Anlamadım (0.0): Alternatif yaklaşım gerektiğini belirtir.

4.3. Pedagojik Teorilerin Entegrasyonu

Pedagojik teoriler, Business Logic Layer'da LLM istemini yönlendirmek için kullanılır, böylece yanıtların pedagojik olarak hizalanması sağlanır.

1. **Yakınsal Gelişim Alanı (ZPD) Hesaplama**: Vygotsky'nin ZPD teorisi, öğrencinin mevcut ve potansiyel seviyesi arasındaki optimal öğrenme bölgesini tanımlar. ZPD algoritması, öğrencinin son 20 etkileşimdeki başarı oranına (**success_rate**) ve ortalama zorluk seviyesine (**avg_difficulty**) göre seviyeyi ayarlayarak **optimal zorluk düzeyini** belirler. Bu yaklaşım, FuzzMonte-RAG'ın önerdiği gibi, öğrenen yeterliliğini sürekli değişken olarak modelleme ihtiyacına yönelik sezgisel bir çözümüdür.
2. **Bloom's Taksonomisi Seviye Tespiti**: Sorular, kelime eşleştirme yoluyla altı Bloom seviyesinde kategorize edilir. LLM istemine, "**Bu soru Bloom seviye {level} gerektiriyor. Cevabı öğrencinin {current_zpd_level} seviyesine uygun ver**" gibi bir şablon dahil edilir.
3. **Bilişsel Yük Yönetimi**: Sunulan bilgi miktarı ve karmaşıklığı kontrol edilir. Karmaşık cevaplar **3-5 parçağa bölünür (Chunking)** ve bilgi aşamalı olarak sunulur (Progressive Disclosure). Eğer hesaplanan bilişsel yük bir eşiği aşarsa, yanıt basitleştirilir ve örneklerde ayrılır.

5. Deneysel Tasarım ve Metrikler

Sistemin etkinliğini ölçmek için dört ana metrik belirlenmiştir:

1. Öğrenci Memnuniyeti:

$\text{satisfaction_score} = (\text{positive_feedback}) / (\text{total_feedback})$. Hedef, > 0.75 puana ulaşmaktadır.

2. **Öğrenci Katılımı (Engagement)**: Oturum süresi, oturum başına soru sayısı ve elde tutma oranının ağırlıklı toplamıdır. Hedef, %20+ artış sağlamaktır.

3. **Öğrenme Etkinliği**: Ön test/son test tasarımları ile ölçülür. Hedef, standart RAG (kontrol grubu) karşısında %15+ daha yüksek skor ($p<0.05$) elde etmektir.

4. **Sistem Performansı ve Güvenilirlik**: Yanıt süresinin 2 saniyenin altında olması ve doğruluk iyileşmesinin baseline'a göre %>10 olması hedeflenir.

6. Tartışma ve Sonuç

Eğitsel-KBRAG, RAG teknolojisini eğitim alanına özgü olarak adapte eden, konuşma belleği, aktif öğrenme ve pedagojik entegrasyonu birleştiren kapsamlı bir sistem önermektedir.

6.1. Temel Katkılar ve Çıkarımlar

- **Sürekli İyileştirme Döngüsü:** Emoji tabanlı mikro-geri bildirim mekanizması, geleneksel RAG sistemlerinin aksine, her etkileşimde sistemin otomatik olarak güncellenmesini ve gerçek zamanlı adaptasyonunu sağlar.
- **Pedagojik Odak:** ZPD, Bloom ve Bilişsel Yük Teorisi gibi eğitim teorilerinin mimari düzeyde entegrasyonu, genel alan RAG sistemlerinin aksine, her yanıtın pedagojik prensiplere göre şekillendirilmesini sağlar.
- **Konuşma Belleği Tabanlı Profilleme:** AL4RAG'ın konuşma kayıtları yaklaşımını annotation yerine profillemeye dönüştürerek, uzun vadeli öğrenci profilleri oluşturur ve her etkileşimden öğrenir. Amber'in çok ajanlı hafıza yönetimi konseptiyle uyumlu olarak, öğrencinin öğrenme yolculuğunun bağılamsal sürekliliğini sağlar.

6.2. Sınırlılıklar ve Gelecek Çalışmalar

Bu karmaşık mimari, doğal olarak bazı operasyonel zorlukları beraberinde getirir. Amber ve CDF-RAG gibi yinelemeli ve ajan tabanlı optimizasyon sistemleri, Vanilla RAG'a göre **daha yüksek gecikmeye** neden olur. Gelecekteki çalışmalar, gelişmiş Makine Öğrenimi (ML) modellerinin ZPD hesaplayıcıya entegrasyonunu, SDLChat'ta görülen gibi motivasyon açıklarını gidermeye yönelik stratejiler geliştirmeyi ve CACS ağırlıklarının **Pekiştirmeli Öğrenme (RL)** ile otomatik optimizasyonunu içerecektir.

Kaynakça (Seçili ve Odaklanmış 10 Kaynak)

1. Asai, A., Wu, Z., Wang, Y., Sil, A., & Hajishirzi, H. (2024). **SELF-RAG: Learning to Retrieve, Generate, and Critique Through Self-Reflection.** *ICLR 2024*.
2. Bai, Y., et al. (2024). **Pistis-RAG: Enhancing Retrieval-Augmented Generation with Human Feedback.** *arXiv preprint arXiv:2404.15654*.
3. Cohn, C., et al. (2025). **CoTAL: Human-in-the-Loop Prompt Engineering for Generalizable Formative Assessment Scoring.** *Journal of Educational Psychology*.
4. CDF-RAG authors. (2025). **Causal Dynamic Feedback for Adaptive Retrieval-Augmented Generation (CDF-RAG).** *Conference Paper*.
5. Geng, X., et al. (2025). **Enhancing RAG with Active Learning on Conversation Records: Reject Incapables and Answer Capables (AL4RAG).** *Huazhong University of Science and Technology & iWudao Tech..*
6. Kovari, A. (2025). **AI Gem: Context-Aware Transformer Agents as Digital Twin Tutors for Adaptive Learning.** *Sensors*.
7. Liu, M., et al. (2025). **Enhancing self-directed learning and Python mastery through integration of a large language model and learning analytics dashboard (SDLChat).** *Brit J Educational Tech.*
8. Liu, Z., et al. (2025). **LPITutor: an LLM based personalized intelligent tutoring system using RAG and prompt engineering.** *Journal of Educational Computing Research*.
9. Persona-RAG authors. (2025). **Investigating Pedagogical Teacher and Student LLM Agents: Genetic Adaptation Meets Retrieval Augmented Generation Across Learning Style.** *Conference Paper*.
10. Qin, Q., et al. (2025). **Towards Adaptive Memory-Based Optimization for Enhanced Retrieval-Augmented Generation (Amber).** *Conference Paper*.